


UNIVERSIDADE
DE PERNAMBUCO

Universidade de Pernambuco
Escola Politécnica de Pernambuco
Programa de Pós-Graduação em Engenharia de Computação

**Lucas Matheus Rodrigues dos Santos**

# FedCHAMP - Um Framework de Aprendizado Federado Multi-Problema Baseado em Agrupamento de Protótipos para Imagens Médicas

Pré-projeto de Dissertação apresentado ao Programa de Pós-Graduação em Engenharia de Computação como parte dos requisitos necessários para a defesa da dissertação de mestrado.

Prof. Dr. Leandro Honorato de Souza Silva
Orientador(a)

Prof. Dr. Bruno José Torres Fernandes
Co-orientador(a)

Recife, 2026

# Resumo

O desenvolvimento de modelos de inteligência artificial para aplicações médicas enfrenta desafios significativos relacionados à disponibilidade e ao compartilhamento de dados entre instituições, frequentemente limitados por restrições de privacidade, segurança e heterogeneidade dos dados. Frequentemente, um treinamento organizado a partir de várias fontes pode causar um aumento geral na capacidade de generalização em modelos de inteligência artificial tornando-os mais robustos e com menor necessidade de que uma única instituição provenha uma grande quantidade de dados. O aprendizado federado pode tornar esse tipo de desafio possível através do aprendizado colaborativo, mantendo a privacidade dos dados de cada participante. No entanto, o aprendizado federado multi-tarefa introduz um novo problema chamado transferência negativa, onde ocorre o cancelamento dos pesos durante a fase de agregação em cenários de dados heterogêneos (Non-IID). Portanto, este projeto de pesquisa propõe o desenvolvimento do FedCHAMP (Federated Clustering and Hierarchical Aggregation for Multi-Problems), um framework de Aprendizado Federado Multi-Domínio e Multi-Tarefa (Multi-Domain-Task) focado em imagens médicas, capaz de lidar simultaneamente com diferentes tarefas preditivas (classificação, segmentação e detecção) e variados domínios de imagem (radiografia, mamografia, tomografia, ultrassom).

**Palavras-chave:** Aprendizado Federado; Imagens Médicas; Heterogeneidade de Dados; Agregação Hierárquica; Protótipos; Transferência Negativa.

# Abstract

The development of artificial intelligence models for medical applications faces significant challenges related to the availability and sharing of data among institutions, which are often limited by privacy, security, and data heterogeneity constraints. Frequently, training organized from multiple sources can lead to a general increase in the generalization capacity of artificial intelligence models, making them more robust and reducing the need for a single institution to provide a large amount of data. Federated learning makes addressing this challenge possible through collaborative learning, maintaining the privacy of each participant's data. However, multi-task federated learning introduces a new problem called negative transfer, where the cancellation of weights occurs during the aggregation phase in heterogeneous data scenarios (Non-IID). Therefore, this research project proposes the development of FedCHAMP (Federated Clustering and Hierarchical Aggregation for Multi-Problems), a Multi-Domain-Task Federated Learning framework focused on medical imaging, capable of simultaneously handling different predictive tasks (classification, segmentation, and detection) and varied image domains (radiography, mammography, tomography, ultrasound).

**Keywords:** Federated Learning; Medical Imaging; Data Heterogeneity; Hierarchical Aggregation; Prototypes; Negative Transfer.

# Sumário

Capítulo 1
Introdução e Motivações.....6
Capítulo 2
Proposta e Justificativa.....8
2.1 Objetivos.....9
2.1.1 Objetivo Geral.....9
2.1.2 Objetivos Específicos.....9
Capítulo 3
Estado da Arte.....10
3.1 Aprendizado Multitarefa (MTL) em Imagens Médicas.....10
3.2 Aprendizado Federado Multitarefa e o Desafio da Transferência Negativa.....10
Capítulo 4
Metodologia.....12
4.1 Etapa 1: Desacoplamento Corpo-Cabeça.....12
4.2 Etapa 2: Mecanismo de Agrupamento e Agregação via Protótipos para Modelo Único 12
4.3 Configuração Experimental e Bases de Dados.....14
4.4 Baselines para Comparação.....14
4.5 Validação das Hipóteses e Métricas de Avaliação.....15
Capítulo 5
Resultados Parciais.....16
Capítulo 6
Cronograma.....17
Capítulo 7
Considerações Parciais.....18
Principais Referências.....19

**Atualizar se necessário e/ou adicionar um sumário automático.*

# Capítulo 1

# Introdução e Motivações

A área de imagens médicas tem sido profundamente transformada pelo Aprendizado Profundo (Deep Learning). No entanto, a construção de modelos robustos exige vastos conjuntos de dados, o que esbarra em rigorosas regulamentações de privacidade (como a LGPD e a HIPAA), impedindo a centralização de exames de pacientes. O aprendizado federado se apresenta como uma solução para treinamentos colaborativos entre diversos participantes mantendo a privacidade de cada um deles, sem a necessidade de que os seus dados sejam enviados a um servidor central (AMIN; AHMAD; LOH, 2025). Na prática, esse processo de treinamento independente e privado, mas colaborativo, pode enfrentar desafios severos em cenários reais quando os participantes possuem bases de dados com distribuições heterogêneas (Non-IID) e heterogeneidade de rótulos e domínios (SUN et al., 2024; SEN; BORCEA, 2024).

Além disso, modelos federados tradicionais, como o FedAvg, assumem um único objetivo unificado. Quando esses modelos com agregação "ingênua" trabalham num contexto com múltiplos rótulos e domínios distintos, é causado o efeito de transferência negativa de conhecimento. Esse efeito se dá porque um participante, ou grupo de participantes, possui conhecimentos divergentes em relação aos outros, causando uma neutralização dos gradientes durante o processo de agregação (ZHUANG et al., 2023).

A implementação de um modelo único nesse cenário ajuda o sistema a aprender representações visuais universais e compartilhadas que beneficiam todos os participantes, mitigando a escassez de dados em clínicas menores. Sendo assim, aquele participante que possui pouquíssimos dados de um domínio específico, em que ele é o único ou um dos poucos participantes que detém dados rotulados para realizar um treinamento, será muito beneficiado porque os dados de outros participantes facilitam a aprendizagem do modelo sobre o contexto geral do objetivo (SUN et al., 2024).

Nesse contexto, é investigado como o Aprendizado Federado Multi-Problema pode unificar diferentes tarefas (segmentação, classificação, detecção) e variadas modalidades de imagem (Tomografia, Ressonância, Raio-X, Mamografia, Ultrassom) (RHANOUI; ALAOUI BELGHITI; MIKRAM, 2025). Atuando diretamente no processo de agregação dos pesos num ambiente federado, o sistema propõe ser capaz de lidar com múltiplos domínios e tarefas simultaneamente (SEN; BORCEA, 2024).

Para viabilizar a solução do problema proposto, a separação da cabeça e corpo do modelo ajuda na personalização dos modelos para cada cliente, que pode enfrentar

diferentes tipos de problemas e tarefas de visão computacional, enquanto o agrupamento baseado em protótipos lida diretamente com a problemática do cancelamento de conhecimento oriundo da “transferência negativa” (KUANG et al., 2024).

Durante a construção do sistema, é avaliado qual o tipo de modelo ideal capaz de funcionar como backbone para toda a rede. Na primeira etapa, serão realizados os experimentos preliminares onde modelos baseados em CNN (YOLO, ResNet, MobileNetV2, VGG16) e Transformers (ViT, Swin) serão selecionados, avaliando a capacidade de generalização de cada arquitetura. Na segunda etapa, serão avaliadas as melhores alternativas para lidar com a transferência negativa através de método de agrupamento por protótipos.

Dessa maneira, este trabalho será avaliado em conjuntos de datasets de imagens médicas refletindo o problema apresentado através de um estudo de caso prático. Com base neste contexto e motivações, definem-se os pilares metodológicos que guiam esta pesquisa:

**Problema de Pesquisa:** Durante o processo de agregação dos pesos num ambiente federado que lida com múltiplos domínios e tarefas, os conhecimentos somados podem ser cancelados durante a agregação ingênua de pesos, gerando transferência negativa e incapacitando o aprendizado.

**Pergunta de Pesquisa:** A separação do corpo e cabeça de um modelo somada ao agrupamento baseado em protótipos garante que os diferentes conhecimentos não serão cancelados durante o aprendizado federado multi-task-domain?

**Hipóteses de Pesquisa:** Para responder a esta pergunta, formulam-se as seguintes hipóteses:

- H1: Os conhecimentos, quando evita-se a agregação ingênua de pesos, não serão mais cancelados pela transferência negativa.
- H2: O treinamento converge mais rapidamente, já que não é atrapalhado durante a agregação dos pesos.
- H3: A abordagem multi-domain-task supera o treinamento separado exclusivamente por tarefas (tasks) e/ou problemas, ou treinamentos isolados (standalone), em cenários de dados limitados.

# Capítulo 2

# Proposta e Justificativa

A presente pesquisa propõe o desenvolvimento e a validação de uma arquitetura inovadora de Aprendizado Federado Multi-Problema e Multi-Tarefa (Multi-Domain-Task Federated Learning), nomeada **FedCHAMP** (Federated Clustering and Hierarchical Aggregation for Multi-Problems), focada na solução da transferência negativa e do cancelamento de pesos gerados durante o treinamento colaborativo de inteligência artificial em imagens médicas. A abordagem central do projeto consiste em intervir diretamente no processo de agregação dos parâmetros no servidor, utilizando duas estratégias conjuntas: a separação arquitetural da rede em "corpo e cabeça" (body-head decoupling) e um mecanismo de agrupamento baseado em protótipos.

Nesta proposta, o "corpo" da rede atuará como um extrator de características generalista, compartilhado globalmente para processar variadas modalidades de imagens médicas, como radiografias, tomografias, mamografias e ultrassons. Simultaneamente, as "cabeças" da rede serão isoladas e mantidas localmente em cada dispositivo para lidar com a personalização de tarefas específicas de cada instituição, como segmentação, detecção ou classificação de patologias. Para garantir que as atualizações dos modelos não se cancelem ao serem somadas no servidor global, os protótipos locais atuarão como guias: o servidor avaliará a similaridade destes protótipos para agrupar e agregar apenas os parâmetros de clientes que possuam distribuições e conhecimentos matematicamente compatíveis.

A justificativa para esta pesquisa fundamenta-se na insuficiência dos algoritmos federados convencionais, como o FedAvg, para lidar com as condições reais do ecossistema de saúde (AMIN; AHMAD; LOH, 2025). Na prática clínica, há um cenário extremo de dados não-IID caracterizado pela alta heterogeneidade de rótulos e de domínios (SUN et al., 2024). Quando métodos tradicionais realizam a "agregação ingênua" dos pesos de instituições focadas em patologias ou modalidades de exames completamente distintas, os gradientes entram em conflito. Isso provoca a neutralização do conhecimento (transferência negativa), incapacitando o aprendizado global (ZHUANG et al., 2023).

Por outro lado, o treinamento de modelos isolados (standalone) em clínicas locais esbarra na limitação crítica da escassez de dados (SUN et al., 2024). Assim, o FedCHAMP justifica-se por permitir uma maior capacidade de colaboração privada num único framework, no qual as instituições médicas poderão se beneficiar mutuamente da extração de características visuais mais generalista. Isso mitiga o problema de dados escassos em clínicas menores, impede a destruição do aprendizado de domínios conflitantes e preserva a

confidencialidade dos dados dos pacientes.

## 2.1 Objetivos

### 2.1.1 Objetivo Geral

Propor e validar um framework de Aprendizado Federado Multi-Domínio e Multi-Tarefa (Multi-Domain-Task), fundamentado na separação arquitetural de corpo e cabeça e no agrupamento guiado por protótipos, visando impedir o cancelamento de pesos e mitigar a transferência negativa durante o processo de agregação, garantindo um aprendizado eficiente e privado em aplicações e modalidades de imagens médicas heterogêneas.

### 2.1.2 Objetivos Específicos

1. Projetar a arquitetura baseada no desacoplamento corpo-cabeça: Adaptar uma rede neural de forma que as camadas iniciais (corpo extrator de características) sejam compartilhadas globalmente para múltiplas modalidades, enquanto as camadas de decisão (cabeças) permaneçam estritamente locais para a personalização das tarefas de visão computacional de cada cliente.
2. Desenvolver o mecanismo de clusterização baseado em protótipos: Implementar uma regra de agregação avançada no servidor central que substitua a agregação ingênua, utilizando a similaridade de protótipos para criar agrupamentos, assegurando que apenas conhecimentos afins e compatíveis sejam somados.
3. Avaliar a mitigação da transferência negativa e eficiência de convergência: Validar matematicamente se a abordagem proposta impede que os conhecimentos sejam cancelados durante a agregação e se proporciona uma convergência de treinamento mais rápida, já que os gradientes não são atrapalhados durante a soma.
4. Comparar a capacidade de generalização contra Baselines: Testar o framework em cenários de dados limitados, verificando sua superioridade em relação aos métodos de treinamento standalone e modelos treinados separadamente por problemas ou tarefas exclusivas

# Capítulo 3

# Estado da Arte

Nos últimos anos, o Aprendizado de Máquina voltado para imagens médicas evoluiu de abordagens centralizadas e restritas a um único problema para arquiteturas distribuídas, capazes de processar simultaneamente diversos domínios e tarefas clínicas. Para contextualizar a solução proposta neste projeto, este capítulo mapeia os principais avanços e as limitações remanescentes nas áreas de Aprendizado Multitarefa (MTL), Aprendizado Federado Multitarefa (FMTL) e no uso de protótipos em redes colaborativas.

## 3.1 Aprendizado Multitarefa (MTL) em Imagens Médicas

A análise de imagens médicas frequentemente exige a execução de tarefas complementares, como classificar a severidade de uma patologia e, simultaneamente, segmentar a área afetada do tumor. Historicamente, redes neurais costumavam ser treinadas de forma independente para cada tarefa, o que aumentava o custo computacional e ignorava as sinergias entre os problemas.

Para resolver isso, abordagens de Aprendizado Multitarefa (MTL) ganharam destaque. O princípio fundamental do MTL, especificamente através do compartilhamento rígido de parâmetros (hard parameter sharing), consiste em utilizar camadas iniciais compartilhadas (o "corpo" da rede) para extrair representações visuais gerais, ramificando-se em camadas finais específicas (as "cabeças") para cada tarefa. (RHANOUI; ALAOUI BELGHITI; MIKRAM, 2025) propuseram um sistema MTL simultâneo para classificação e segmentação de tumores em modalidades diversas (Ressonância Magnética, Raio-X, imagens dermatoscópicas e histopatologia digital) utilizando arquiteturas U-Net com base em extratores VGG16 e MobileNetV2. Os autores demonstraram que o modelo multitarefa supera consistentemente os métodos de tarefa única, alcançando alta precisão em segmentação (acima de 95%) e classificação (até 90%). Embora esses estudos comprovem que compartilhar o "corpo" da rede melhora a capacidade de generalização e previne o overfitting, eles operam em ambientes centralizados. Esse estudo reforça como o aprendizado simultâneo de diferentes domínios e tarefas podem se beneficiar de sinergias no aprendizado de características comuns. Porém, na prática, a centralização de exames esbarra em rigorosas regulamentações de privacidade, como a LGDP ou HIPPA, o que impede a replicação desses métodos sem adaptações arquiteturais profundas.

## 3.2 Aprendizado Federado Multitarefa e o Desafio da Transferência Negativa

O Aprendizado Federado (FL) permite que múltiplas instituições treinem modelos colaborativos sem transferir dados locais. Contudo, algoritmos tradicionais de agregação, como o FedAvg, assumem homogeneidade de tarefas e dados (dados IID). Quando aplicados em ecossistemas que possuem distribuições não-IID ou executam tarefas completamente distintas (heterogeneidade de tarefas), a agregação ingênua força a união de gradientes conflitantes. Esse fenômeno resulta na "**transferência negativa**", onde o conhecimento de uma tarefa cancela ou degrada os pesos da outra durante a agregação global.

Pesquisadores têm proposto diferentes soluções para mitigar o cancelamento de pesos no FMTL. (ZHUANG, 2023) introduziram o método MAS (Merge and Split), focado em treinar múltiplas tarefas simultâneas em dispositivos com recursos limitados. O MAS agrupa inicialmente todas as tarefas em um modelo global multitarefa único (Merge) e, após as rodadas iniciais, calcula "escores de afinidade" matemáticos entre elas. Para evitar a transferência negativa, o servidor central divide fisicamente a rede em vários modelos globais independentes (Split), separando permanentemente as tarefas conflitantes. Embora eficaz, a separação física adotada pelo MAS fragmenta o aprendizado; as clínicas isoladas param de se beneficiar da robustez de uma representação visual universal extraída por todo o ecossistema.

Buscando uma solução sem fragmentar a rede, (SEN; BORCEA, 2024) propuseram o FedMTL, um sistema que lida com a heterogeneidade de tarefas, gerando modelos personalizados por cliente. O FedMTL adota o compartilhamento de parâmetros rígidos (desacoplamento corpo-cabeça) e evita a soma de pesos conflitantes comparando matematicamente os parâmetros das camadas específicas de tarefas (as cabeças) dos clientes. Utilizando a similaridade de cosseno e o algoritmo Húngaro, o FedMTL exclui da agregação aqueles clientes que possuem pesos divergentes abaixo de um limiar predefinido.

Não existe, portanto, um framework que atue diretamente no processo de agregação global integrando o desacoplamento de corpo e cabeça com a clusterização de clientes guiada por protótipos no servidor. Sendo assim, esta pesquisa fundamenta-se na premissa de que os protótipos fornecem representações de features superiores aos parâmetros brutos de rede para medir a compatibilidade semântica.

# Capítulo 4

# Metodologia

Este capítulo descreve os procedimentos metodológicos, a arquitetura do sistema e o desenho experimental que serão adotados para desenvolver o framework proposto e validar as hipóteses de pesquisa (H1, H2 e H3). O trabalho será conduzido através de simulações computacionais em um ambiente de Aprendizado Federado (FL), estruturado nas etapas descritas a seguir.

## 4.1 Etapa 1: Desacoplamento Corpo-Cabeça

A primeira etapa consiste em projetar a arquitetura de deep learning para suportar o cenário multi-domain-task sem expor as camadas de decisão a conflitos. O modelo será estruturado com base no compartilhamento rígido de parâmetros (hard parameter sharing) adaptado para o ambiente federado:

- Corpo (Extrator de Características Compartilhado): As camadas iniciais e intermediárias da rede formarão o "corpo". Este componente será responsável por aprender características visuais de baixo e médio nível (bordas, texturas, densidades) de forma generalista através das múltiplas modalidades de exames. Apenas os pesos deste corpo serão transmitidos ao servidor para agregação.
- Cabeças (Camadas de Decisão Locais): As camadas finais da rede serão configuradas localmente para refletir o problema específico de cada cliente (ex: uma cabeça densa para classificação de lesões de pele ou uma cabeça de máscara/decodificador para segmentação de tumores cerebrais). As cabeças nunca serão enviadas ao servidor, isolando a fase de inferência de tarefas conflitantes de outros participantes.

Nessa etapa, serão selecionados quais os modelos de CNN ou transformers serão mantidos para os experimentos seguintes. YOLO, ResNet, MobileNetV2, VGG16 e extratores baseados em U-Net aparecem como opções frequentemente utilizadas pela literatura, como em MAS, FedMTL e FedMLP. Bem como, serão avaliados modelos de vision transformers como ViT. Dessa maneira, após os primeiros experimentos, as etapas seguintes serão realizadas baseando-se nessa escolha

## 4.2 Etapa 2: Mecanismo de Agrupamento e Agregação via Protótipos para Modelo Único

Para evitar a "agregação ingênua" (como ocorre no algoritmo FedAvg) e a consequente transferência negativa, a etapa central do trabalho será a implementação de uma regra de agregação hierárquica no servidor global baseada em protótipos, visando a construção de um único modelo global robusto.

Um protótipo é uma representação matemática (um vetor) que resume as características essenciais de uma classe específica ou de um domínio no espaço de características (ou espaço latente) da rede neural. Para entender de forma prática, em vez de olhar para a imagem inteira com todos os seus pixels, a rede neural extrai as características mais importantes (bordas, texturas, densidades). O protótipo é uma representação semântica dessas características. Por exemplo, um protótipo pode resumir a essência visual do que é uma "Pneumonia", um "Tumor Cerebral" ou um "Tecido Saudável".

Como demonstrado na literatura (como no artigo FedMLP), um protótipo local para uma determinada classe é gerado calculando a média dos vetores de características extraídos de todas as amostras de imagens daquela classe presentes no dispositivo local. Ou seja, o cliente processa todas as suas imagens de "tumor", passa pelo corpo da rede neural, e tira a média das representações geradas para criar um único vetor (o protótipo do tumor).

O fluxo ocorrerá da seguinte maneira:

1. Geração de Protótipos Locais: Durante o treinamento, cada cliente calculará representações matemáticas (protótipos) que resumem as características de suas classes ou domínios de imagens no espaço latente da rede.
2. Transmissão: Ao fim da rodada de comunicação, os clientes enviarão ao servidor central os pesos atualizados do "corpo" da rede acompanhados de seus respectivos protótipos locais.
3. Agrupamento no Servidor: O servidor utilizará os protótipos recebidos para calcular métricas de similaridade semântica (como a similaridade de cosseno) entre as distribuições de dados dos clientes. Clientes que possuam protótipos matematicamente compatíveis serão organizados em agrupamentos lógicos (clusters virtuais).
4. Agregação Hierárquica em Duas Fases: A atualização do modelo global único será feita em duas etapas para impedir o cancelamento de pesos:
    - Fase Intra-Cluster (Soma Direta): Primeiro, o servidor agrega os pesos exclusivamente dentro de cada grupo. Como os clientes do mesmo cluster possuem distribuições afins (ex: hospitais focados em pulmão), a soma de seus pesos ocorre sem conflitos, gerando um "modelo de consenso" para cada domínio.
    - Fase Global (Fusão com Mitigação): Em seguida, o servidor funde os modelos de consenso de todos os clusters para atualizar o modelo global único. Para

garantir que consensos de domínios diferentes (ex: Raio-X e Ultrassom) não se cancelem ao serem somados, o servidor aplica uma técnica de resolução de conflitos (como a projeção ortogonal de gradientes ou agregação ponderada pela variância). Isso obriga o "corpo" do modelo global a tornar generalista, acomodando múltiplos domínios sem que o aprendizado de um destrua o do outro.

## 4.3 Configuração Experimental e Bases de Dados

Para simular o cenário médico multi-domain-task real, serão selecionados e pré-processados conjuntos de dados públicos que cobrem diversas modalidades e tarefas. As bases selecionadas incluirão:

- ISIC 2018: Imagens dermatoscópicas para a tarefa de classificação de lesões de pele.
- TCGA-LGG: Imagens de Ressonância Magnética (RM) para segmentação e classificação de tumores cerebrais (gliomas).
- PANDA: Imagens de histopatologia digital para detecção e classificação de câncer de próstata.
- SIIM-ACR: Radiografias de tórax (Raio-X) para segmentação de pneumotórax.

Para espelhar a heterogeneidade estatística (Non-IID) e o desbalanceamento encontrados na saúde, os dados serão distribuídos de forma desigual entre os clientes virtuais utilizando a distribuição de Dirichlet. Para avaliar o impacto em clínicas menores, uma parte considerável dos clientes será configurada com severa escassez de dados (cenários de few-shot learning).

## 4.4 Baselines para Comparação

O desempenho do framework proposto será comparado contra metodologias consolidadas na literatura:

- Standalone (Treinamento Local Isolado): Modelos treinados puramente com os dados locais do cliente, sem colaboração federada.
- FedAvg (Agregação Ingênua): O algoritmo federado padrão que realiza a média dos pesos de todos os clientes indiscriminadamente.
- MAS (Merge and Split): Método que lida com múltiplas tarefas fundindo-as inicialmente e dividindo a rede fisicamente em vários modelos independentes ao longo do treinamento.
- FedMTL: Método federado que evita o cancelamento agregando as redes através da similaridade de pesos brutos baseada na métrica de cosseno usando o algoritmo Húngaro.

Os frameworks FedAvg, MAS e FedMTL possuem implementações disponíveis para replicação de experimentos. Dessa forma, será possível comparar os resultados nas mesmas condições e bases de dados escolhidas.

## 4.5 Validação das Hipóteses e Métricas de Avaliação

Os resultados dos experimentos fornecerão suporte quantitativo para validar as três hipóteses de pesquisa formuladas:

- **Validação da H1 (Mitigação do Cancelamento/Transferência Negativa):**
  - Métricas: Acurácia balanceada e Função de Perda (Loss) para classificação; Coeficiente Dice e Intersection over Union (IoU) para segmentação.
  - Verificação: A H1 será confirmada se a perda (loss) média do modelo proposto for substancialmente inferior à do modelo FedAvg. Além disso, a análise dos vetores de pesos antes e depois do agrupamento deverá comprovar que a agregação por clusters evitou operações de soma com soma zero (cancelamento de gradientes).
- **Validação da H2 (Eficiência e Velocidade de Convergência):**
  - Métricas: Número de rodadas de comunicação (Communication Rounds) e Curva de Função de Perda ao longo do tempo.
  - Verificação: A H2 será aceita caso o gráfico de convergência do framework demonstre uma queda na taxa de erro mais veloz e estável do que os métodos FedAvg e FedMTL, provando que o modelo perde menos tempo re-aprendendo características destruídas por agregações divergentes.
- **Validação da H3 (Superioridade em Cenários de Dados Limitados):**
  - Métricas: Comparação relativa de Acurácia/Dice em clientes com escassez severa de amostras.
  - Verificação: A H3 será validada se os clientes simulando clínicas pequenas obtiverem métricas de diagnóstico (ex: Dice de segmentação > 90%) superiores aos seus respectivos treinamentos Standalone (isolados) ou treinamentos federados separados estritamente por problema, como o MAS. Isso provará que a colaboração estruturada multi-domain-task compensa a falta de dados locais.

# Capítulo 5

# Resultados Parciais

A expectativa central é que o FedCHAMP supere as limitações dos métodos federados tradicionais no cenário multi-domain-task.

Para a primeira hipótese (H1), espera-se comprovar que os conhecimentos somados no servidor não serão cancelados pela transferência negativa. Ao agrupar clientes por similaridade semântica e restringir a soma direta a pesos compatíveis, o modelo deverá apresentar uma Função de Perda (Loss) substancialmente menor e mais estável em comparação à agregação ingênua padrão (como o FedAvg). O resultado principal a ser evidenciado é a preservação do aprendizado, impedindo que as características de um domínio médico cancelem as de outro durante a agregação global.

Em relação à segunda hipótese (H2), os resultados devem demonstrar que o treinamento do framework converge mais rapidamente. Como o modelo não perde tempo re-aprendendo características que teriam sido apagadas por gradientes divergentes, a expectativa é que a curva de erro exiba uma queda muito mais acentuada e suave. Consequentemente, o sistema alcançará a estabilidade e uma alta taxa de acerto exigindo um número significativamente menor de rodadas de comunicação.

Para a terceira hipótese (H3), espera-se que a abordagem supere amplamente os treinamentos isolados (Standalone) e os métodos fragmentados em cenários de extrema escassez de dados. Ao ser comparado especificamente com o método MAS (Merge and Split), que resolve os conflitos dividindo a rede fisicamente em vários submodelos isolados, o framework proposto deverá atingir métricas de diagnóstico muito superiores para as clínicas pequenas que estão inseridas em pequenos agrupamentos. O resultado esperado é provar que a manutenção de um único extrator global de características permite que instituições com poucos exames herdem a robustez visual de toda a rede, compensando sua falta de dados locais de maneira muito mais eficiente do que o isolamento promovido pelo MAS.

# Capítulo 6

# Cronograma

- **Meses 1 a 3:** Revisão bibliográfica e preparação de dados. Realização de estudos aprofundados e seleção das bases de dados públicas.
- **Mês 4:** Configuração do ambiente e baselines. Implementação do ambiente base de simulação federada e o estabelecimento das linhas de base para futuras comparações. Os baselines incluirão os treinamentos Standalone, FedAvg, MAS e FedMTL.
- **Mês 5:** Desacoplamento arquitetural. Adaptação da rede neural para múltiplos domínios focando na separação entre corpo e cabeça.
- **Mês 6:** Agrupamento por protótipos. Implementação da etapa de clusterização de protótipos no servidor global.
- **Mês 7:** Otimização da rede e sistema como um todo.
- **Meses 8 e 9:** Execução de testes massivos e coleta de métricas. Simulação de cenários clínicos reais com dados Non-IID e escassez de amostras. Início do texto final construindo os tópicos iniciais como introdução e fundamentação teórica.
- **Meses 10 a 12:** Análise e finalização. Análise quantitativa final dos resultados contra os baselines para provar a mitigação do cancelamento de pesos. Elaboração do texto final da dissertação.

# Capítulo 7

# Considerações Parciais

A presente pesquisa propõe o FedCHAMP (Federated Clustering and Hierarchical Aggregation for Multi-Problems), uma arquitetura inovadora de Aprendizado Federado Multi-Problema e Multi-Tarefa voltada para imagens médicas. O objetivo central do framework é superar o efeito de transferência negativa e o cancelamento de pesos que ocorrem quando métodos tradicionais realizam a agregação "ingênua" de hospitais com domínios e tarefas muito heterogêneas. Para intervir diretamente nesse processo no servidor, o sistema utiliza duas estratégias conjuntas: a separação arquitetural da rede em "corpo e cabeça" (mantendo as camadas de decisão locais) e um mecanismo de agrupamento baseado em protótipos, garantindo que o servidor agregue apenas os parâmetros de clientes que possuam distribuições e conhecimentos matematicamente compatíveis.

A partir da implementação dessa arquitetura, o estudo projeta três conclusões e validações centrais. Primeiramente, espera-se comprovar que a intervenção evitará que os conhecimentos divergentes sejam cancelados pela transferência negativa durante a soma (H1). Consequentemente, projeta-se que o tempo de treinamento e a velocidade de convergência serão significativamente superiores, já que o aprendizado não será atrapalhado por gradientes em conflito (H2). Por fim, a pesquisa busca atestar que clínicas locais enfrentando limitação e escassez de dados alcançarão uma capacidade diagnóstica muito superior ao colaborar neste ecossistema, superando amplamente o treinamento isolado (standalone) ou separado exclusivamente por tarefas (H3).

# Principais Referências

AMIN, M. S.; AHMAD, S.; LOH, W.-K. Federated learning for Healthcare 5.0: a comprehensive survey, taxonomy, challenges, and solutions. Soft Computing, [S.l.], v. 29, p. 673–700, 2025. https://doi.org/10.1007/s00500-025-10508-z.

KUANG, L.; GUO, K.; LIANG, J.; ZHANG, J. An Enhanced Federated Prototype Learning Method under Domain Shift. [S.l.], 2024. arXiv preprint arXiv:2409.18578. https://arxiv.org/abs/2409.18578.

RHANOUI, M.; ALAOUI BELGHITI, K.; MIKRAM, M. Multi-Task Deep Learning for Simultaneous Classification and Segmentation of Cancer Pathologies in Diverse Medical Imaging Modalities. Onco, [S.l.], v. 5, p. 34, 2025. https://doi.org/10.3390/onco5030034.

SEN, P.; BORCEA, C. FedMTL: Privacy-Preserving Federated Multi-Task Learning. Frontiers in Artificial Intelligence and Applications, [S.l.], v. 392, p. 1993–2002, 2024. https://doi.org/10.3233/FAIA240715.

SUN, Z.; WU, N.; SHI, J.; YU, L.; CHENG, K.-T.; YAN, Z. FedMLP: Federated Multi-Label Medical Image Classification under Task Heterogeneity. In: Proceedings of Medical Image Computing and Computer Assisted Intervention -- MICCAI 2024. [S.l.]: Springer Nature Switzerland, 2024. v. LNCS 15010, p. 394–404.

ZHUANG, W.; WEN, Y.; LYU, L.; ZHANG, S. MAS: Towards Resource-Efficient Federated Multiple-Task Learning. In: 2023 IEEE/CVF International Conference on Computer Vision (ICCV). [S.l.], p. 23357–23367, 2023. https://doi.org/10.1109/ICCV51070.2023.02140.